

A. Bankruptcy dataset 預處理流程與演算法

1. **Feature scaling**：由於本次作業使用 KNN 補值，KNN 仰賴 feature 尺度；若尺度相差太大，KNN 計算距離上會以尺度大的 feature 主導。演算法採用的是 Min-Max Scaling， $x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$ 。
2. **Missing Value**：使用 KNN imputer，針對欄位有缺失的資料，以最鄰近 5 個 neighbor 的目標欄位平均來補值。
3. **Data Unbalancing**：經過檢視，non-bankruptcy 有 6599 筆，但 bankruptcy 只有 220 筆。為了避免在 bankruptcy 上補太多虛假資料，同時達成 perfect balance，因此採用先針對 non-bankruptcy 做 under-sampling，再針對 bankruptcy 做 over-sampling 到 perfect balance，最後兩類皆有 6249 筆資料。
 - (1) **under-sampling**：採用 ENN 而非 random under-sampler，優先刪除在邊界附近的資料點，以降低 noise。
 - (2) **over-sampling**：採用 border line SMOTE，針對邊界附近但並非全數 neighbor 皆為異類的資料點產生偽資料，避免生成 noise 同時，又不是在都是同類中生成偽資料，因此有助於往後模型學習更清晰的分類邊界。
4. **Feature Selection**：因為原始資料有高達 96 個 feature，因此採用先 filter 再 wrapper。
 - (1) **filter**：採用 mutual information 作為衡量指標，保留最高的 40 個 feature。
mutual information 公式為 $I(X; Y) = H(Y) - H(Y | X)$ ，其中 $H(Y)$ 是 entropy，
公式為 $-\sum_y p(y) \log p(y)$ ，用於衡量資料的不確定性。因此 mutual information 越大表示此 feature 對於不確定性降低越有幫助，也就是用此 feature 能夠將 y 分類的越純。
 - (2) **wrapper**：採用 random forest classifier 作為 estimator，指標為 recall (考慮若把 bankruptcy 預測為 non-bankruptcy (FN)，將導致錯誤信任公司，導致嚴重的經濟損失；採用 $\text{recall} = \frac{TP}{TP + FN}$ 有助於降低 FN。選取方式為 backward elimination，實作上採用 recursive feature elimination (RFE)，最後剩餘 15 個 feature。

B. Diamond dataset 預處理流程

1. **Feature scaling**：同樣採用 Min-Max Scaling， $x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$ 。
2. **Encoding**：因為變數取值間有 ordinal 關係，因此採用 label encoding
 - (1) cut：fair、good、very good、premium、ideal 編號為 0-4。
 - (2) color：J 到 D 依序為 0-6。
 - (3) clarity：I1、SI2、SI1、VS2、VS1、VVS2、VVS1、IF 分別為 0-7。

3. Missing Value

(1) numerical feature (包含 y: price)：使用 KNN imputer，針對欄位有缺失的資料，以最鄰近 5 個 neighbor 的目標欄位平均來補值。

(2) categorical feature：做完 label encoding 之後用 KNN classifier，用已補值完畢的 numerical feature 來預測有缺失值的 categorical feature。

4. **Feature Selection**：因為原始資料只有 9 個 feature，因此直接採用 wrapper，直到僅剩餘 6 個特徵為止。實作上同樣採用 backward elimination，estimator 使用 random forest regressor (因為其可以處理 non-linear 的關係，呼應前方針對 categorical 做 label encoding)，performance 指標採用 default 的 R-squared。