

A. **Optimization** 演算法：

cluster 數量由 grid search，嘗試 2、3、4、5 共 4 組數字。決定 Gaussian membership function 的 center 和 sigma 採用 **Gradient Descent**，核心概念在於將最後的輸出依照 Loss Function 由後往前 feedback 到最前層，依照梯度修正 center 和 sigma。

◆ 目標函數：Loss Function = $E = \frac{1}{2}(\hat{y} - y)^2$

◆ 梯度下降更新公式：針對第 i 條規則、第 j 個特徵的 center (c_{ij}) 和 sigma (σ_{ij})。

$$c_{ij}^{(new)} = c_{ij}^{(old)} - \eta \frac{\partial E}{\partial c_{ij}}, \sigma_{ij}^{(new)} = \sigma_{ij}^{(old)} - \eta \frac{\partial E}{\partial \sigma_{ij}}$$

梯度的計算主要由 chain rule 推導如下

◆ 第五層 Output Layer 到第四層 Consequent Layer： $\frac{\partial E}{\partial \hat{y}} = (\hat{y} - y)$ ，這個梯度表示預測與真實值的差異。

◆ 第四層 Consequent Layer 到第二層 Rule Strength Layer：

因為 $\hat{y} = \frac{\sum w_k f_k}{\sum w_k}$ ，所以 $\frac{\partial \hat{y}}{\partial w_i} = \frac{f_i - \hat{y}}{\sum w_k}$ ，這個梯度表示規則的觸發強度對預測值的影響。

◆ 第二層 Rule Strength Layer 到第一層 Fuzzification Layer：

因為 $w_i = \prod_{j=1}^F \mu_{ij}$ ，所以 $\frac{\partial w_i}{\partial \mu_{ij}} = \frac{w_i}{\mu_{ij}}$ ，這個梯度表示第 j 個特徵的 membership function 的影響。

◆ 第一層 Fuzzification Layer：由 Gaussian membership function $\mu_{ij} = \exp\left(-\frac{(x_j - c_{ij})^2}{2\sigma_{ij}^2}\right)$ ，

可推出 $\frac{\partial \mu_{ij}}{\partial c_{ij}} = \mu_{ij} \cdot \frac{x_j - c_{ij}}{\sigma_{ij}^2}$ ， $\frac{\partial \mu_{ij}}{\partial \sigma_{ij}} = \mu_{ij} \cdot \frac{(x_j - c_{ij})^2}{\sigma_{ij}^3}$ 。

◆ 因此根據 chain rule $\frac{\partial E}{\partial c_{ij}} = \frac{\partial E}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial w_i} \frac{\partial w_i}{\partial \mu_{ij}} \frac{\partial \mu_{ij}}{\partial c_{ij}}$ ，可得

$$\frac{\partial E}{\partial c_{ij}} = (\hat{y} - y) \cdot \bar{w}_i \cdot (f_i - \hat{y}) \cdot \frac{x_j - c_{ij}}{\sigma_{ij}^2}, \frac{\partial E}{\partial \sigma_{ij}} = (\hat{y} - y) \cdot \bar{w}_i \cdot (f_i - \hat{y}) \cdot \frac{(x_j - c_{ij})^2}{\sigma_{ij}^3}$$

此公式的意涵：

(1) $(\hat{y} - y)$ ：預測值朝向真實值的方向修正。

(2) $\bar{w}_i \cdot (f_i - \hat{y})$ ：某條 rule 的預測值朝向整體預測值的方向修正；觸發強度越強修正越明顯。

(3) $\frac{x_j - c_{ij}}{\sigma_{ij}^2}$ ：此資料點位於 center 的左方/右方修正。

B. 程式實作

本次作業針對 Gradient Descent 採用 PyTorch 套件實作，超參數有

- ♦ $\text{patience} = 100$ ：連續 100 次迭代沒有 improve 就停止運算。
- ♦ $\text{epochs} = 1000$ ：一個 epoch 是將整個訓練資料集完整地進行一次 feed-forward 計算輸出與誤差與 feedback 更新參數的過程；共執行最多 1000 次。

C. diamond dataset 預測結果

根據下表，與沒有最佳化 (Ref.) 比較，使用 ANFIS 的梯度下降迭代最佳化後在各指標都有所進步，但執行時間增加，分的 cluster 數量越多，執行時間大致越長。其中 cluster 數量 = 3 有最好的各項指標，且經過最佳化後的 MSPE < 10%，表示預測和真實值誤差已經 < 10%，比沒有最佳化的 Ref. 優。至於 cluster 數量 = 4 或 5，增加群集數後並未帶來額外資訊，反而增加模型複雜度。training 和 validation 的評估指標差異小，沒有 overfitting 現象。

Alg.	cluster	time (sec)	dataset	parameter		evaluation criteria				
				premise	consequent	R^2	MAPE	MSE	RMSE	NRMSE
Ref.	2	0.01	Train	24	14	0.9401	11.44	940746	969	0.0525
			Valid	24	14	0.9421	11.33	988731	994	0.0538
ANFIS	2	4.83	Train	24	14	0.9476	10.78	822714	907	0.0491
			Valid	24	14	0.9499	10.47	855548	924	0.0501
	3	4.24	Train	36	21	0.9551	9.95	705127	839	0.0454
			Valid	36	21	0.9600	9.65	682736	826	0.0447
	4	5.74	Train	48	28	0.9501	10.47	783443	885	0.0479
			Valid	48	28	0.9562	10.29	746835	864	0.0468
	5	6.78	Train	60	35	0.9512	9.86	766671	875	0.0474
			Valid	60	35	0.9529	9.67	804124	896	0.0485

D. bankruptcy 預測結果

根據下表，由於資料量比 diamond 小，因此執行時間較短，而 cluster 數量 = 5 比 4 的執行時間多，推測是因為資料的結構關係，使 cluster 數量 = 5 跑的迭代次數較少導致。綜合各個評估指標，最好的 model 是 cluster 數量 = 2 的 ANFIS，training 和 validation set 差異小，沒有 overfitting 的問題發生，且比沒有最佳化的 Ref. 優。注意到 model 訓練結果大多 recall 比 precision 好，表示 model 針對有破產的公司的識別度高，但預測破產的公司中，約有 10% 屬於誤判。

Alg.	cluster	time (sec)	dataset	parameter		evaluation criteria			
				premise	consequent	Acc.	Prec.	Recall	F1
Ref.	2	0.02	Train	60	32	0.8743	0.8101	0.9616	0.8794
			Valid	60	32	0.8453	0.7689	0.9665	0.8564
ANFIS	2	0.62	Train	60	32	0.9291	0.9080	0.9472	0.9272
			Valid	60	32	0.9147	0.8731	0.9609	0.9149
	3	0.65	Train	90	48	0.9177	0.8966	0.9353	0.9155
			Valid	90	48	0.9013	0.8622	0.9441	0.9013
	4	0.94	Train	120	64	0.9166	0.8822	0.9520	0.9158
			Valid	120	64	0.9120	0.8687	0.9609	0.9125
	5	0.66	Train	150	80	0.9017	0.8575	0.9520	0.9023
			Valid	150	80	0.8853	0.8301	0.9553	0.8883