

Preprocessing: 使用作業一 dataset (已經補值、類別不平衡處理、資料縮放、categorical feature 採用 label encoding 維持 order 都已處理完畢)

diamond dataset: y 值為連續變數 price，因此根據上課時老師所述，將 price 放入 clustering 和其餘 feature 一起分群，增加 clustering 的資訊。

bankruptcy dataset: y 值為破產與否，非 0 即 1，計算距離時易主導 clustering 結果，因此不把 y 值放入，分完群後再識別 clustering 所產生的自然潛在結構是否與破產有關。

A. K means


流程：針對 $k = 1$ 到 10 跑 K means 演算法，使用 elbow method 找出 elbow 位置，決定 optimal K 值，並以 silhouette score 判斷分群好壞。

diamond dataset 結果：K = 4 為最佳 cluster 數量，也有最高的 silhouette score。

K	2	3	4
inertia	7624.04	5726.32	4433.31
silhouette	0.3010	0.3035	0.3269

K	5	6	7
inertia	3948.07	3592.95	3148.99
silhouette	0.2940	0.2792	0.2898

K	8	9	10
inertia	3083.10	2694.17	2511.23
silhouette	0.2463	0.2649	0.2754



分群結果解釋：觀察每個 cluster 各個 feature (scale 後) 的平均值與標準差，可發現：

cluster 0: 平均 carat 最大，x、y、z 尺寸也最大，因此屬於最大顆的鑽石族群，價格也明顯最高。這群的 color 與 clarity 都屬中等，表示它們不一定擁有最好的顏色或淨度，但因為重量與尺寸較大，因此整體價格最高，屬於大顆高價型鑽石。

cluster 1: carat 最小，尺寸也最小，因此整體屬於小顆鑽石。這群價格最低，但 clarity 平均最高，代表淨度最好、內含物較少。這可說是一群「小顆但品質乾淨」的鑽石。

cluster 2: carat 與尺寸都偏小到中等，價格也不高，clarity 則偏低；但 color 數值最偏向高等的 D 類 (無色)，顏色特徵與其他群差異最大。因此這群比較像是顏色特徵明顯，但整體品質普通的中小型鑽石。


cluster 3: 此群鑽石 carat 與尺寸介於 Cluster 1 與 Cluster 0 之間，屬於中等大小，clarity、價格也屬中等。這群的 color 平均最低，代表顏色等級相對較差，因此整體可視為除顏色較差外，尺寸、淨度與價格都適中的平衡型鑽石。

bankruptcy dataset 結果：**K = 3** 為最佳 cluster 數量，也有最高的 silhouette score。

K	2	3	4
inertia	418.10	301.73	256.11
silhouette	0.4151	0.4460	0.3277

K	5	6	7
inertia	223.96	202.81	185.95
silhouette	0.3462	0.2908	0.3088

K	8	9	10
inertia	176.41	158.70	147.10
silhouette	0.2941	0.2975	0.2837



分群結果解釋：觀察每個 cluster 各個 feature (scale 後) 的平均值與標準差，可發現：

cluster 0：企業在獲利能力方面屬於中等，但 debt ratio、current liabilities 與 borrowing dependency 偏高，代表負債壓力較大、較依賴借款經營。整體來看破產風險較高。

cluster 1：企業在 Persistent EPS、Net profit before tax、Net Income to Total Assets 與 Retained Earnings to Total Assets 等獲利指標上最高，代表獲利能力與資產運用效率最佳。同時 debt ratio、liability to equity 與 current liability 指標最低。整體來看屬於高獲利、低負債、低風險的健康企業群。

cluster 2：企業在 EPS、Net profit before tax、Net Income to Total Assets 與 retained earnings 等獲利相關指標皆最低，整體獲利能力較差。同時 debt ratio、liability to equity、borrowing dependency 與 current liabilities 指標偏高。整體來看是最高破產風險的企業。

B. Fuzzy C means

Fuzzy C means 利用歸屬函數允許一個資料點同時屬於多個 cluster，因此 elbow method 計算變異時公式納入歸屬度，另外加上 Fuzzy partition coefficient (FPC)，定義為


$\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^c u_{ik}^2$ ，其中 u_{ik} 為歸屬度，coefficient 越大表示分群越清楚而不模糊。

diamond dataset 結果：**K = 3 or 4** 為最佳 cluster 數量，K = 4 有最高的 FPC。

K	2	3	4
inertia	20198.99	9273.72	3835.99
FPC	0.8098	0.7828	0.8335

K	5	6	7
inertia	3292.98	2873.31	2468.06
FPC	0.7808	0.6291	0.6401

K	8	9	10
inertia	2002.12	1793.24	1433.17
FPC	0.5146	0.4962	0.4713




bankruptcy dataset 結果：**K = 3 or 4** 為最佳 cluster 數量，K = 4 有最高的 FPC。

K	2	3	4
inertia	2415.69	1056.16	307.33
FPC	0.8738	0.8793	0.9360

K	5	6	7
inertia	240.15	198.30	177.62
FPC	0.9207	0.8197	0.7879

K	8	9	10
inertia	147.39	114.86	101.74
FPC	0.7713	0.6466	0.5972



其中 Fuzzy C means 可以調整參數 m ， m 越大表示 membership function 越模糊 (m 趨近於 1 則越像是 K means, 但會有 zero division error, 所以最小設為 1.01)。經由針對 diamond dataset 試驗， m 越大 inertia 越低 (因為權重被壓縮)，FPC 也越低 (因為分群越模糊)。


m	1.01	1.5	2	2.5	3	5
加權 inertia*	4433.30	4397.60	3835.99	2745.31	1718.89	157.15
FPC	1.0000	0.9860	0.8335	0.6383	0.5019	0.3142

* $J_m = \sum_{i=1}^n \sum_{j=1}^k u_{ij}^m \|x_i - c_j\|^2$ ，是 Fuzzy C means 的目標函數。

C. Agglomerative

由於直接使用所有 sample 做 agglomerative clustering，需要計算所有 sample pair 之間的距離，需要 $O(n^2)$ 的記憶體空間複雜度，經過實測會導致 memory error，因此採用老師上課時的建議：先用 flat method (本題採用 K means) 做 clustering 篩選出 sub-cluster (本題留下 1000 個 sub-cluster) 後，再用 agglomerative clustering。方式有 simple linkage (sub-cluster 距離以最近資料點距離為準)、average linkage (平均距離)、complete linkage (最遠距離)，與另外實作的 ward (目標式採用群內變異)。


diamond dataset 結果：四種 linkage 分群結果高度一致，且和 K means 結果有類似：從 elbow method 來看 $k = 3$ 或 4 為最佳分群數量，silhouette score 也在 $k = 4$ 同時達到四種方法的共同峰值 (0.6208)，顯示此資料存在清晰的自然群結構。在 $k = 2$ 至 4 最後合併階段，complete 與 average linkage 的 inertia 幾乎完全重疊，代表兩者在這份資料上採取了相近合併路徑。合併到 $k = 4$ 之前 ward linkage 由於分群目標與 inertia 最類似，因此數值較低。



K	Single Linkage		Complete Linkage		Average Linkage		Ward Linkage	
	inertia	silhouette	inertia	silhouette	inertia	silhouette	inertia	silhouette
2	800.34	0.4749	478.19	0.6116	478.19	0.6116	631.17	0.5443
3	319.07	0.5599	300.66	0.5400	300.66	0.5400	269.76	0.5696
4	141.54	0.6208	141.54	0.6208	141.54	0.6208	141.54	0.6208
5	140.67	0.6051	120.30	0.5129	140.68	0.5703	119.18	0.5187
6	139.81	0.5546	113.79	0.4528	139.76	0.5538	109.64	0.5023
7	138.89	0.5381	107.39	0.4259	138.89	0.5381	103.49	0.4367
8	137.72	0.5150	96.83	0.4351	137.72	0.5150	97.62	0.3232
9	137.35	0.4814	95.96	0.4208	131.87	0.4508	91.91	0.3138
10	136.97	0.4125	94.59	0.4222	131.50	0.4177	87.37	0.2177

* ward linkage 的 merge distance 單位是 inertia，所以尺度和其他三種 linkage 不同。

*因為以 200 個 sub-cluster 開始分群，此處 inertia 與 silhouette 無法和 K means 比較。




bankruptcy dataset 結果：bankruptcy 的分群結果在不同 linkage 上差異較 diamond 大。
Single linkage 前四個 k 的 inertia 幾乎不降 (960 → 925)，silhouette 也偏低且不穩定。
直到 k = 5、6 inertia 才出現大幅降低 (478 → 178)，silhouette 也在 k = 8 達到最高的 0.7359。這代表 bankruptcy 資料在 single linkage 下，真正的群結構要到 k = 8 才被切出來，但 k 這麼大解釋性較低。

Complete linkage 在 k = 2、3 inertia 幾乎不動 (498 → 494)，k = 4 才出現大幅降低 (194)，silhouette 也同步回升至 0.6334。最佳 k = 4。

Average linkage 行為與 complete 幾乎一致，k = 2、3 同樣偽分群，k = 4 才真正分裂。
k = 4、5 的 silhouette 維持在 0.63 左右，是相對平穩的區間。k = 10 出現異常高點 (0.7229)，推測是衛星群拉高效應。最佳 k = 4 或 5。

Ward linkage 表現最穩健且最一致，推測是因為 Ward linkage 的 clustering objective function 最能呼應 silhouette score 和 inertia。Inertia 從 k=2 起持續積極下降，silhouette 在 k=4 到 k=6 維持在 0.71~0.73，且沒有出現斷崖或異常跳動。最佳 k=4。



K	Single Linkage		Complete Linkage		Average Linkage		Ward Linkage	
	inertia	silhouette	inertia	silhouette	inertia	silhouette	inertia	silhouette
2	960.29	0.2966	498.28	0.5395	498.28	0.5395	474.24	0.5209
3	957.62	0.2414	494.52	0.4904	494.52	0.4904	198.31	0.6321
4	925.62	0.1353	194.36	0.6334	194.36	0.6334	102.51	0.7116
5	478.15	0.3980	172.63	0.5834	193.58	0.6317	80.78	0.7204
6	177.98	0.6183	157.04	0.5966	192.31	0.6069	65.19	0.7336
7	156.26	0.5963	153.36	0.5900	176.73	0.6108	59.39	0.6155
8	60.45	0.7359	57.55	0.7306	155.01	0.5888	53.66	0.5674
9	59.50	0.7301	52.19	0.6884	151.32	0.5822	48.83	0.5763
10	58.88	0.7276	47.77	0.6300	55.52	0.7229	44.71	0.5699