

Preprocessing：使用作業一 dataset (補值、類別不平衡處理、資料縮放、categorical feature 採用 label encoding 維持類別間的 order 都已處理完畢)

A. 處理流程


1. 從整個 dataset 中抽樣 10%，再從中抽 70% 為 training set，剩餘 30% 為 validation set。

dataset	training set	validation set	features
diamond	3776	1618	6
bankruptcy	875	375	15

2. **feature scaling**：使用 Min-Max scaling，將 feature 取值縮放到 $[0, 1]$ ，公式為

$$x_{new} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

由於 diamond dataset 中的 target variables：price 有嚴重的右偏，因此將 **price 取 log**，減少 skewness，讓資料更為常態，並降低 outlier 的影響，以提升模型訓練效果。



3. **Fuzzy System Identification**：採用 Adaptive Neural Fuzzy Inference System (**ANFIS**) 的五層 feed-forward 演算法；最後第五層結果 feedback 到第一層重新最佳化的迭代流程在 HW4 中。

- (1) **Fuzzification Layer**：使用 K means clustering，並與 HW2 相同，在 diamond dataset 中納入 target variable：price 當作 features，指定分為兩個 clusters。針對每個資料，依照以下的 membership function 計算此資料分別屬於這兩個 cluster 的歸屬程度。

- ♦ **triangular** membership function：本次作業採用 cluster 內資料的平均值作為三角形最高點 (b)，三角形最左與最右端取值則是 cluster 內資料的最小 (a) 與最大值 (c)；由於 validation set 的 feature 取值可能超過此 interval，若直接 cap 到 0 容易導致 if-then rule 相乘時，規則觸發強度為 0，因此將最小與最大值 **往外擴展 10% 的 margin**。總共所需要的 premise parameters 數量為 $2 (\text{clusters}) \times 3 (a, b, c) \times 6 \text{ or } 15 (\text{features}) = 36 (\text{diamond}) \text{ or } 90 (\text{bankruptcy})$ 。公式為

$$\mu(x; a, b, c) = \max\left(\min\left(\frac{x - a}{b - a}, \frac{c - x}{c - b}\right), 0\right)$$

- ♦ **Gaussian** membership function: 本次作業採用 cluster 內資料的平均值 (c) 與標準差 (σ) 作為 Gaussian function 的兩個參數。總共所需要的 premise parameters 數量為 $2 (\text{clusters}) \times 2 (c, \sigma) \times 6 \text{ or } 15 (\text{features}) = 24 (\text{diamond}) \text{ or } 60 (\text{bankruptcy})$ 。公式為

$$\mu(x; \sigma, c) = e^{\frac{-(x-c)^2}{2\sigma^2}}$$

(2) **Rule Firing Strength Layer**

若考慮所有可能組合的 if-then rule，diamond / bankruptcy 分別會有 2^6 與 2^{15} 條規則，容易導致 overfitting。由於本次作業是一次將整個關聯式資料庫跑 clustering，不是逐個 feature 分群，因此只定義兩條 fuzzy rules：分別就是屬於 cluster-1 以及 cluster-2 的歸屬程度，定義為各個 feature membership 符合度的乘積。公式為

$$w_i(x) = \prod_{j=1}^n \mu_{i,j}(x_j)$$

，其中 $w_i(x)$ 是資料 x 歸屬於 cluster i 的程度，是資料 x 每個特徵 j 屬於 cluster i 的程度相乘。

(3) **Normalization Layer**

計算每條規則的觸發強度佔總觸發強度的比例，用於解決因為一個資料點在兩個 membership function 總和不一定為 1 的問題；如此可以讓每個資料點歸屬於所有 if-then rule 的程度相加為 1。公式為

$$\overline{w}_i = \frac{w_i}{w_1 + w_2}$$

(4) **Consequent Layer**

diamond dataset 是 regression 問題，因此每個 if-then rule 的 output 是採用局部的 linear regression；bankruptcy 是 classification 問題，此次作業採用 logistic regression。因此針對 diamond / bankruptcy dataset，需要的 consequent parameters 數量分別為 $2 (\text{clusters}) \times (6+1) \text{ or } (15+1) (\text{features 係數個數} + \text{截距}) = 14 \text{ or } 32 (+\text{logistic regression intercept} = 33)$ 。


但此次作業並非 train 兩個 local regression，而是水平展開成一個有 14 (diamond) / 33 (bankruptcy) 個 features+intercept 的 linear regression 一起 train，以得到 global optimum。可以合併的原因在於 linear 與 linear function 相加仍為 linear。

(5) **Overall Output Layer**

最後依照每條 rule 的 weight 與預測值，線性組合即可得到最終輸出 = $\sum_i f_i \overline{w}_i$ 。

B. diamond dataset 預測結果

雖然 Triangular membership function 需要校估左、中、右三個參數，比 Gaussian membership function 的平均與標準差多了一個，但 Triangular membership function 的訓練時間卻比較短，或許是因為 Gaussian membership function 計算上比較複雜。至於預測結果，training / validation set 的各項指標都相近，沒有 overfitting 的現象發生；但 Gaussian membership function 各項指標都比 Triangular membership function 好：觀察 original v.s. fitted y plot 可以發現 triangular membership function 雖然已經擴展 margin 了，但仍有部分資料集都完全不屬於兩個 if-then rule，因此被預測為 0。



Gaussian membership function

- ◆ Premise parameters: 24
- ◆ Consequent parameters : 14
- ◆ Total parameters: 38
- ◆ Training time: 0.0102 s
- ◆ Evaluation

score	R-squared	MAPE	MSE	RMSE	NRMSE
train	0.940170	11.448875	940746.46	969.92	0.052519
validation	0.942135	11.336676	988731.13	994.34	0.053877

Triangular membership function

- ◆ Premise parameters: 36
- ◆ Consequent parameters : 14
- ◆ Total parameters: 5.0
- ◆ Training time: 0.0020 s
- ◆ Evaluation

score	R-squared	MAPE	MSE	RMSE	NRMSE
train	0.759860	16.782097	3775875	1943.16	0.105218
validation	0.772642	15.982057	3.88486	1971.01	0.106795

C. bankruptcy dataset 預測結果

雖然 Triangular membership function 需要校估左、中、右三個參數，比 Gaussian membership function 的平均與標準差多了一個，但訓練時間也都很短，約為 0.02 秒；略為比 diamond dataset 長的原因可能是 logistic regression 需要用 maximum likelihood，沒有像是 least square 一樣有封閉形式的解。至於預測結果，training / validation set 的各項指標都相近，沒有 overfitting 的現象發生；accuracy、precision 與 F1 score 都是 Triangular membership function 較優，但 recall 是 Gaussian membership function 高出了約 3%。

Gaussian membership function

- ◆ Premise parameters: 60
- ◆ Consequent parameters : 33
- ◆ Total parameters: 93
- ◆ Training time: 0.0209 s
- ◆ Evaluation

score	accuracy	precision	recall	F1 score
train	0.8743	0.8101	0.9616	0.8794
validation	0.8453	0.7689	0.9665	0.8564

Triangular membership function

- ◆ Premise parameters: 90
- ◆ Consequent parameters : 33
- ◆ Total parameters: 123
- ◆ Training time: 0.0206 s
- ◆ Evaluation

score	accuracy	precision	recall	F1 score
train	0.9063	0.8747	0.9376	0.9051
validation	0.8933	0.8458	0.9497	0.8947